

Detección de Manipulaciones Copy-Move y Splicing en Audio usando Técnicas de Aprendizaje Profundo

Néstor Marín Gómez
Jose Antonio Ruiz Heredia

Directores:

Luis Javier García Villalba
Daniel Povedano Álvarez


Departamento de Ingeniería del Software e Inteligencia Artificial
Facultad de Informática
Universidad Complutense de Madrid
Junio de 2024



Índice

1. Introducción
2. Estado del arte
3. Preproceso y modelo
4. Experimentación y resultados
5. Conclusiones
6. Trabajo futuro

Motivación



Introducción

Aplicaciones

Industria musical

Investigación criminal

Aspectos jurídicos


Derechos de autor

Seguridad y vigilancia

OBJETIVO


No solamente detectar una posible modificación, sino decir que tipo de modificación ha sido.

Redes Neuronales Convolucionales (CNN)




Arquitectura de una Red Neuronal Convolutiva

Representación del audio



Representación con forma de onda



Representación con espectrograma

N FFT

HOP LENGTH

N MELS



Tipos de modificaciones

Splicing de **inserción**



Splicing de **sustitución**

Splicing de **eliminación**

Tipo de modificación	Transcripción
Original	Me encanta jugar al fútbol.
Inserción	Me encanta jugar al fútbol <i>con él.</i>
Sustitución	Me encanta jugar al <i>tenis.</i>
Eliminación	Me encanta jugar al fútbol.

Tipos de modificaciones

Copy move





Estado del arte

Uso de Redes Neuronales Convolucionales.

Uso de la ventana deslizando para encontrar diferencias en segmentos.

Limitaciones encontradas:

Detección de solo un tipo de modificación.

Poco uso de técnicas de aumentos de datos.

Escasez de conjuntos de datos modificados de uso público.



Creación del conjunto de datos


Conjunto de datos de referencia : **TIMIT**

Contenido inicial: 1.681 audios en inglés de entre 3 y 7 segundos.


Modificaciones en el conjunto de datos basadas en el artículo “*An Encoder-Decoder Architecture for Audio Splicing Detection and Localization*”.

Resultado: 20.160 audios modificados de entre 2 y 3 segundos.

Creación del conjunto de datos











Número de audios según su duración



Número de audios según su categoría

Aumento de datos de audio (ADA)

- Ruido Gaussiano
- Ganancia
- Cambio de Tono
- Invertir



ConvNextv2_femto.fcmae_f_in1k

Fully Convolutional Masked Autoencoder (FCMA)

Pre entrenado con *Image-Net1k*

Nuestra Propuesta


16.000 Hz

hop_length de 512

30 capas entrenables

n_fft de 1024

n_mels de 224




- 5,2 Millones de parámetros
- 224x224 píxeles




Custom Image Dataset

Dataframes




Espectrograma de Mel




Redimensionar


Con silencio




Resize



Normalizar datos




Aumento de datos




Flujo de trabajo del modelo


Tratamiento de los datos




Entrenamiento del modelo




Validación





Audios rellenados con silencio





Representación de espectrograma con silencio con ADA





Representación de espectrograma con silencio original



Audios con redimensionamiento



Representación de espectrograma de mel



Representación de espectrograma MFCC


Comparación experimentos

Nº Experimento	Redimensionado	ADA	Espectrograma
1 (BASE)	NO	NO	MEL
2	NO	NO	MEL
3	NO	SI	MEL
4	SI	NO	MEL
5	SI	NO	MFCC

Tabla con especificaciones de cada experimento

Nº Experimento	F1-score (%)	Precisión (%)	Pérdida
1 (BASE)	77,42	76,67	66,25
2	89,13	86,81	55,58
3	89,41	86,69	52,51
4	87,61	85,54	54,61
5	82,09	77,56	66,41

Tabla con métricas de cada experimento






Métricas del mejor modelo

Etiqueta	Precisión (%)	Sensibilidad (%)	<i>F1-Score</i> (%)	Muestras
Original	97,0	97,6	97,3	336
Copy-move	86,9	88,7	87,8	2016
Splicing	88,6	86,7	87,6	2017

Tabla con las métricas del mejor modelo





Gradio

Audio Classifier

Inference

Select here the audio files

SA1_0.WAV	93.8 KB	↓	×
SA1_1.WAV	93.8 KB	↓	×
SA1_2.WAV	93.8 KB	↓	×
SA1.WAV	99.4 KB	↓	×
SA2.WAV	78.2 KB	↓	×
SI454.WAV	137.2 KB	↓	×

Predicted Class(es)

['copy-move', 'copy-move', 'copy-move', 'original', 'original', 'original']

Classify




Seleccionar una muestra de audio



Realizar clasificación

Conclusiones



Trabajo futuro

Posibles trabajos futuros



Utilizar arquitecturas más avanzadas

Aplicar más técnicas de *ADA*

Grad-MAP para análisis del modelo

Ampliar el número de categorías


Localizar la posición de la manipulación



Contributions


Contributions

1. Online courses.




2.

José: Code to generate the dataset.
Néstor: Audio spectrogram representation.




3.

José: Preprocessing of the audio samples.
Néstor: Audio data augmentations.




4.

José: Code to create the CSV and *CustomImageDataset*.
Néstor: Training and gradio.




5. Writing the report



Gracias por su tiempo y atención




Espectrogramas




Representación con espectrograma de Mel

Espectrogramas



Representación con MFCC con distinto valor de n_{mel}

Media de épocas de entrenamiento



Nº Experimento	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
1 (BASE)	33	39	37	46	49
2	23	15	36	30	17
3	44	50	33	34	28
4	44	33	41	30	37
5	25	45	41	20	22

Tabla con número de épocas de cada experimento



Gradio

Audio Classifier

Inference

Select here the audio files

Coloque el archivo aquí
- 0 -
Haga click para cargar

Predicted Class(es)

Classify



Seleccionar una muestra de audio

Conclusiones

